

# 1 Price DOES Matter! Modeling Price and Interest Preferences in Session-based Recommendation

## 1.1 论文来源

Zhang X, Xu B, Yang L, et al. Price does matter! modeling price and interest preferences in session-based recommendation[C]//Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2022: 1684-1693.

## 1.2 论文代码

<https://github.com/Zhang-xiaokun/CoHHN>

## 1.3 论文笔记

SBR指的是基于会话的推荐。基于会话的推荐算法(Session-based Recommendation)是指在用户未登录状态下, 仅仅依赖匿名会话进行用户下一个行为预测的一种算法, 在许多领域(如电商、短视频、直播等)有着重要的作用. <https://zhuanlan.zhihu.com/p/303233631>

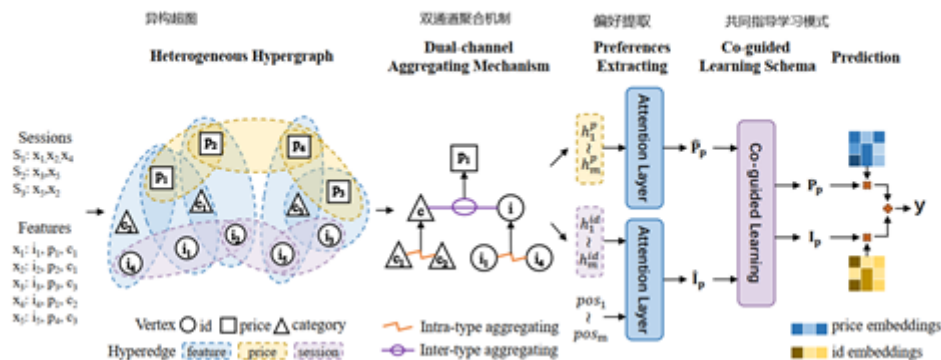
令 $R(u)$ 是根据用户在训练集上的行为给用户作出的推荐列表, 而 $T(u)$ 是用户在测试集上的行为列表。对用户 $u$ 推荐 $N$ 个物品 (记为 $R(u)$ ) , 令用户 $u$ 在测试集上喜欢的物品集合为 $T(u)$ , 然后通过准确率/召回率评测推荐算法的精度:

$$\text{Precision} = \frac{\sum_u |R(u) \cap T(u)|}{\sum_u |R(u)|}$$

准确率描述最终的推荐列表中有多少比例是发生过的用户—物品评分记录; 召回率描述有多少比例的用户—物品评分记录包含在最终的推荐列表中。 <https://www.cnblogs.com/shenxiaolin/p/9309749.html>

目前基于会话的推荐方法只关注对用户兴趣偏好的建模, 而忽略了商品的一个关键属性, 即价格。许多营销研究表明, 价格因素显著影响用户的行为, 用户的购买决策同时由价格和兴趣偏好决定。然而, 将价格偏好纳入基于会话的推荐并非易事。首先, 很难处理来自商品各种特征的异构信息以捕获用户的价格偏好。其次, 在确定用户选择时很难对价格和兴趣偏好之间的复杂关系进行建模。

为了解决上述挑战, 我们提出了一种用于基于会话的推荐的新方法协同引导异构超图网络 (CoHHN) 。针对第一个挑战, 我们设计了一个异构超图来表示异构信息和它们之间丰富的关系。然后设计双通道聚合机制来聚合异构超图中的各种信息。之后, 我们通过注意力层提取用户的价格偏好和兴趣偏好。对于第二个挑战, 设计了一种共同引导的学习方案来模拟价格和兴趣偏好之间的关系, 并增强彼此的学习。最后, 我们根据商品特征以及用户的价格和兴趣偏好来预测用户行为。对三个真实世界数据集的大量实验证明了所提出的 CoHHN 的有效性。进一步的分析揭示了价格对于基于会话的推荐的重要性。



## 1.4 启发

我认为这篇论文最大的亮点在于所提出的价格量化方法。物品的绝对价格不足以确定该物品是否昂贵。例如，200 美元对于一部手机来说可能很便宜，但同样的价格对于一盏灯来说就非常高了。因此，我们必须根据商品类别将商品价格离散化为不同的价格级别，以便可以在不同类别之间进行比较。某个商品类别的价格分布更接近逻辑分布，而不是广泛使用的均匀分布。Logistic分布的概率密度函数呈现出中间偏高、两侧偏低特征。这篇论文就是根据Logistic分布将商品价格离散化。这种方法也符合我们在实际生活中的常规认识。

# 2 A Counterfactual Collaborative Session-based Recommender System

## 2.1 论文来源

Song W, Wang S, Wang Y, et al. A counterfactual collaborative session-based recommender system[C]//Proceedings of the ACM Web Conference 2023. 2023: 971-982.

## 2.2 论文代码

<https://github.com/wzsong17/COCO-SBRS>

## 2.3 论文笔记

Mean reciprocal rank (MRR)：reciprocal rank是指，第一个正确答案的排名的倒数。MRR是指多个查询语句的排名倒数的均值。公式如下：

$$MRR = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{rank_i}$$

MRR是一个国际上通用的对搜索算法进行评价的机制，其评估假设是基于唯一的一个相关结果，即第一个结果匹配，分数为 1，第二个匹配分数为 0.5，第 n 个匹配分数为 1/n，如果没有匹配的句子分数为 0。最终的分数为所有得分之和。<https://www.cnblogs.com/shenxiaolin/p/9309749.html>

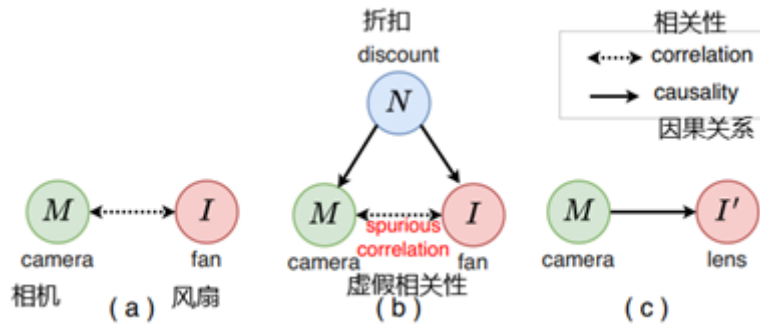
在传统的位置编码中，位置编码向量是根据位置索引计算得出的固定向量，用于表示输入序列中每个位置的位置信息。

而反向位置编码则是一种动态位置编码方法，它允许模型在训练和推理时动态地生成位置编码。这种方法通常结合注意力机制，使模型能够根据输入序列的内容和上下文动态地学习位置信息，而不是依赖固定的位置编码向量。

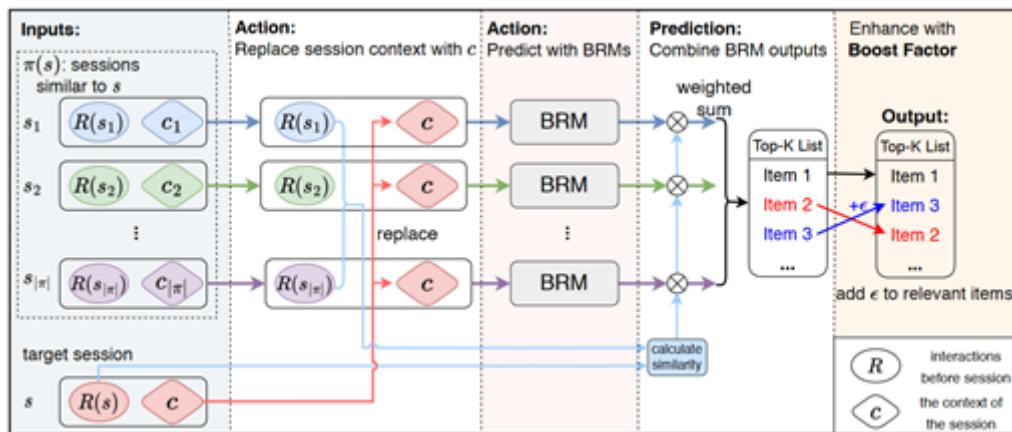
通过引入反向位置编码，模型可以更好地处理不同长度的输入序列，并且能够更好地泛化到未见过的位置信息。这种方法有助于提高模型在处理长序列任务时的性能和泛化能力。

大多数基于会话的推荐系统（SBRS）专注于从用户当前会话中观察到的项目中提取信息来预测下一个项目，而忽略会话外影响用户选择的原因（称为外部会话原因，OSC）的项目。然而，这些原因在现实世界中广泛存在，很少有研究调查它们在 SBRS 中的作用。在这项工作中，我们从因果推理的角度分析了 SBRS 中 OSC 的因果关系和相关性。我们发现 OSC 本质上是 SBRS 中的混杂因素，这导致用于训练 SBRS 模型的数据中出现虚假相关性。为了解决这个问题，我们提出了一种名为 COCOSBRS（COunterfactual COllaborative Session-Based Recommender Systems）的新型 SBRS 框架，以学习 SBRS 中 OSC 和用户-项目交互之间的因果关系。COCO-SBRS 首先采用自监督的方法来预训练推荐模型，为每个用户选择数据中的项目设计原因伪标签来指导训练过程。接下来，COCO-SBRS 根据预训练推荐模型的输出，考虑因果关系，采用反事实推理来推荐项目，以缓解数据稀疏问题。因此，COCO-SBRS 可以学习数据中的因果关系，防止模型学习虚假相关性。我们在三个真实世界数据集上进行的广泛实验的实验结果证明了我们提出的框架相对于十个代表性 SBRS 的优越性。

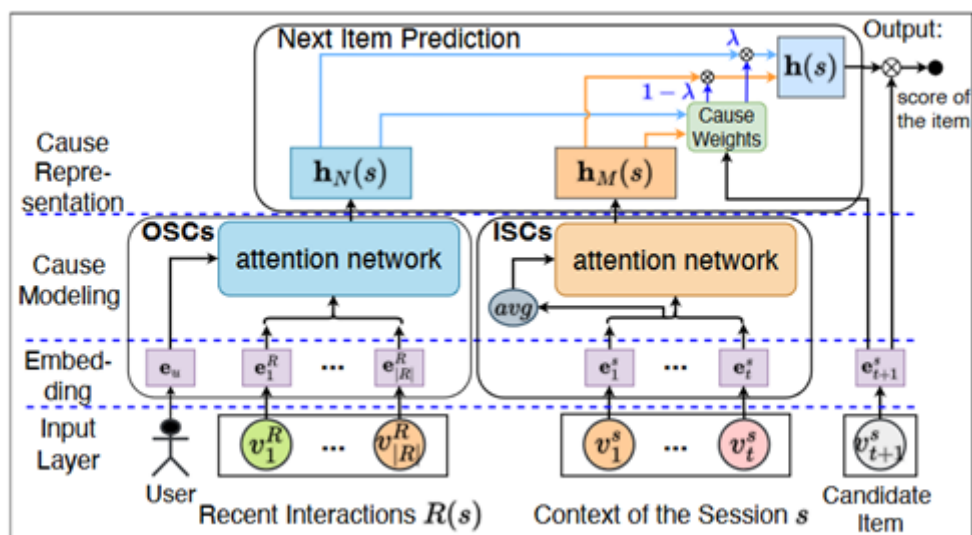
虚假相关性：例如，当超市中的相机和风扇同时打折时，许多用户会购买它们在一起是因为它们比平常便宜。假设相机和风扇分别是图 1 (a) 所示的 ISC（会话内原因） $M$  和下一项  $I$ 。SBRS 模型在会话中学习共现模式  $M \leftrightarrow I$ 。如果用户购买相机，即使折扣结束，模型也会向他/她推荐风扇，因为存在大量同时包含相机和粉丝的会话/交易。然而，相机和风扇在用途上并无关联。用户购买风扇并不是因为购买了相机，而是因为风扇打折。因此，这种共现相关性可能会导致 SBRS 中的错误建模问题。



COCO 首先预训练一个推荐模型来学习 SBRS 中 ISC、OSC 和用户-项目交互之间的因果关系，然后根据与本会话具有相同 ISC 和 OSC 的一些邻居会话来预测会话的下一个项目，并且用于模拟用户在邻居会话中的选择的推荐模型。在预训练阶段，我们采用自监督的方法来训练推荐模型，为每个用户-项目交互设计原因的伪标签来指导模型的训练。为缓解在预测阶段缺少所需 ISC 和 OSC 的会话的问题，我们采用反事实推理来使用所需 ISC 和 OSC 生成会话。



其中所使用的BRM的结构为：



## 2.4 启发

从实验中使用的三个数据集的详细统计信息来看，COCOSBRS这个模型他应该更擅长处理数据比较稀疏的数据集，例如在Last.fm中，users数量为1101，items数量为711，他的实验各方面指标就相对于其他items数量多的数据集如Reddit要好一些。采用了反事实的方法帮助COCOSBRS在Last.fm中能有比较好的表现，但当用于Delicious和Reddit这种user参与的会话比较多的场景时， $R(s)$ 的选择就需要一些更明确的量化指标，否则考虑用户历史交互信息这一操作给模型带来的有效信息可能会被大量的交互信息稀释， $R(s)$ 是包含  $u$  在  $s$  之前最近的交互的集合。

# 3 Self-Supervised Hypergraph Convolutional Networks for Session-based Recommendation

## 3.1 论文来源

Xia X, Yin H, Yu J, et al. Self-supervised hypergraph convolutional networks for session-based recommendation[C]//Proceedings of the AAAI conference on artificial intelligence. 2021, 35(5): 4503-4511.

## 3.2 论文代码

<https://github.com/xiixin1998/DHCN>

## 3.3 论文笔记

基于图神经网络（GNN）的SBR方法将项目转换视为成对关系，忽略了项目之间复杂的高阶信息。超图提供了一种捕获超配对关系的自然方法，但其在 SBR 中的潜力尚未被开发。在本文中，我们通过将基于会话的数据建模为超图来填补这一空白，然后提出一种超图卷积网络来改进 SBR。此外，为了增强超图建模，我们设计了另一种基于超图线图的图卷积网络，然后通过最大化通过两个网络学习的会话表示之间的互信息，将自监督学习集成到网络的训练中，作为改进推荐任务的辅助任务。由于这两种类型的网络都是基于超图的，可以将其视为超图建模的两个通道，因此我们将我们的模型命名为DHCN（双通道超图卷积网络）。

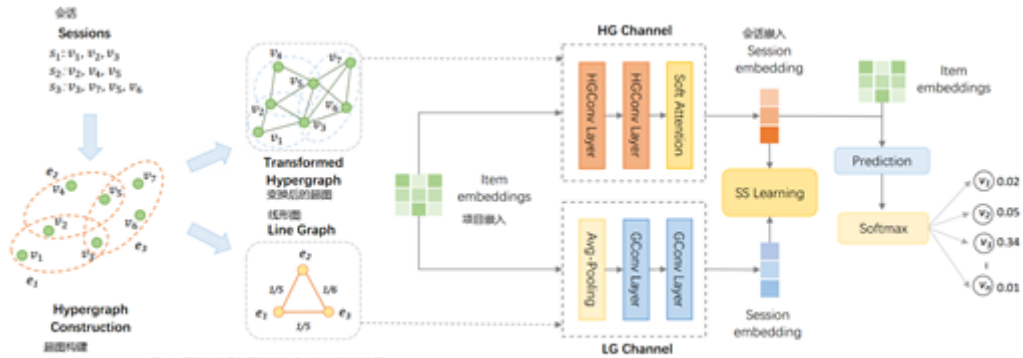


图 1: 超图的构造和所提出的 DHCN 模型的流程。  
Figure 1: The construction of hypergraph and the pipeline of the proposed DHCN model.

通过在超图通道中堆叠多个层，我们可以借用超图卷积的优势来生成高质量的推荐结果。然而，由于每个超边仅包含有限数量的项目，因此固有的数据稀疏问题可能会限制超图建模带来的好处。为了解决这个问题，我们引入了线图通道，并创新地将自监督学习（Hjelm et al. 2018）集成到我们的模型中，以增强超图建模。线图是在超图的基础上，将每个超边建模为一个节点，重点关注超边的连通性，描述会话级关系。

本文开发了双通道超图卷积网络（DHCN），其两个通道覆盖两个图。直观上，我们网络中的两个通道可以看作是描述会话内部和会话间信息的两个不同视图，而每个通道对另一个通道的信息知之甚少。通过自监督学习最大化两个通道学习到的会话表示之间的共有信息，两个通道可以从彼此获取新信息，以提高自己在项目/会话特征提取中的性能。然后，我们将推荐任务和自监督任务统一在主辅学习框架下。

### 3.4 启发

将会话交互序列建模为图的优势之一就是不用为了方便模型处理而对长度不够的序列进行填充和对长度太长的序列进行截断。为我们在数据处理时增加了灵活性。但是基于图的推荐我感觉很难考虑到item的价格、类别等等可以帮助推荐的辅助信息。